고객을 세그먼테이션하자 [프로젝트]

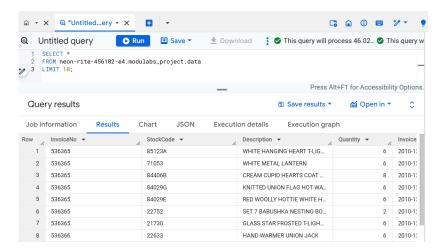
11-2. 데이터 불러오기

데이터 살펴보기

• 테이블에 있는 10개의 행만 출력하기

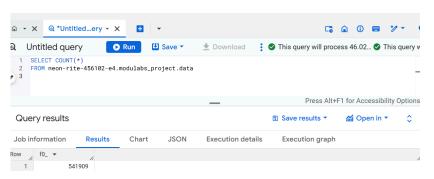
```
SELECT *
FROM neon-rite-456102-e4.modulabs_project.data
LIMIT 10;
```

[결과 이미지를 넣어주세요]



• 전체 데이터는 몇 행으로 구성되어 있는지 확인하기

SELECT COUNT(*)
FROM neon-rite-456102-e4.modulabs_project.data
[결과 이미지를 넣어주세요]



데이터 수 세기

• COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기

SELECT

COUNT(InvoiceNo) AS COUNT_InvoiceNo,

COUNT(StockCode) AS COUNT_StockCode,

COUNT(Description) AS COUNT_Description,

COUNT(Quantity) AS COUNT_Quantity,

COUNT(InvoiceDate) AS COUNT_InoivceDate,

COUNT(UnitPrice) AS COUNT_UnitPrice,

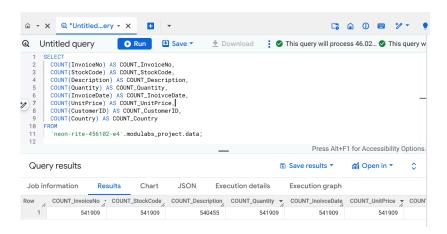
COUNT(CustomerID) AS COUNT_CustomerID,

COUNT(Country) AS COUNT_Country

FROM

`neon-rite-456102-e4`.modulabs_project.data;

[결과 이미지를 넣어주세요]



11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- 각 컬럼 별 누락된 값의 비율을 계산
 - 각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

```
SELECT
'InvoiceNo' AS column_name,
ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM neon-rite-456102-e4.modulabs_project.data
UNION ALL
SELECT.
'StockCode' AS column_name,
ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM neon-rite-456102-e4.modulabs_project.data
UNION ALL
SELECT
'Description' AS column_name,
ROUND(SUM(CASE WHEN Description IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM neon-rite-456102-e4.modulabs_project.data
UNION ALL
SELECT
'Quantity' AS column_name,
ROUND(SUM(CASE WHEN Quantity IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM neon-rite-456102-e4.modulabs_project.data
```

UNION ALL

SELECT

'InvoiceDate' AS column_name,

ROUND(SUM(CASE WHEN InvoiceDate IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage FROM neon-rite-456102-e4.modulabs_project.data

UNION ALL

SELECT

'UnitPrice' AS column_name,

ROUND(SUM(CASE WHEN UnitPrice IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage FROM neon-rite-456102-e4.modulabs_project.data

UNION ALL

SELECT

'CustomerID' AS column_name,

 $ROUND(SUM(CASE\ WHEN\ CustomerID\ IS\ NULL\ THEN\ 1\ ELSE\ 0\ END)\ /\ COUNT(*)\ *\ 100,\ 2)\ AS\ missing_percentage$ FROM neon-rite-456102-e4.modulabs_project.data

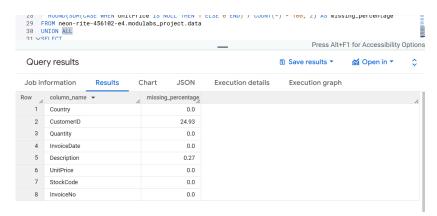
UNION ALL

SELECT

'Country' AS column_name,

ROUND(SUM(CASE WHEN Country IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage FROM neon-rite-456102-e4.modulabs_project.data

[결과 이미지를 넣어주세요]



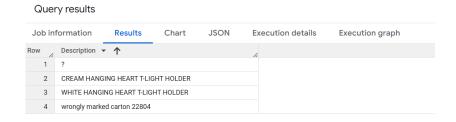
결측치 처리 전략

• StockCode = '85123A' 의 Description 을 추출하는 쿼리문을 작성하기

SELECT DISTINCT Description
FROM neon-rite-456102-e4.modulabs_project.data
WHERE StockCode = '85123A';

[결과 이미지를 넣어주세요]

LMS 예시와 다르게 ascending sort 했습니다.



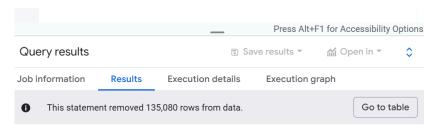
결측치 처리

• DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시

DELETE FROM neon-rite-456102-e4.modulabs_project.data WHERE CustomerID IS NULL OR Description IS NULL;

[결과 이미지를 넣어주세요]

영어환경이어 결과가 영어로 나옵니다.



11-5. 데이터 전처리(2): 중복값 처리

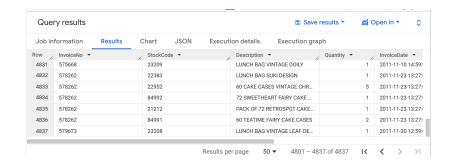
중복값 확인

- 중복된 행의 수를 세어보기
 - 8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기

```
SELECT *
FROM neon-rite-456102-e4.modulabs_project.data
GROUP BY
InvoiceNo,
StockCode,
Description,
Quantity,
InvoiceDate,
UnitPrice,
CustomerID,
Country
HAVING COUNT(*) > 1;
```

[결과 이미지를 넣어주세요]

마지막 행이 보이게 이미지 잘랐습니다.



중복값 처리

- 중복값을 제거하는 쿼리문 작성하기
 - CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트

CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.data AS SELECT
DISTINCT *
FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]

영문환경이어서 결과가 영어로 나옵니다.



11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

• 고유(unique)한 InvoiceNo 의 개수를 출력하기

SELECT COUNT(DISTINCT InvoiceNo)
FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]

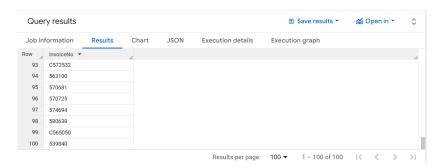


• 고유한 InvoiceNo 를 앞에서부터 100개를 출력하기

SELECT DISTINCT InvoiceNo FROM neon-rite-456102-e4.modulabs_project.data LIMIT 100;

[결과 이미지를 넣어주세요]

LMS의 예시와 다르지만 C로 시작되는 invoice 찾을 수 있습니다.

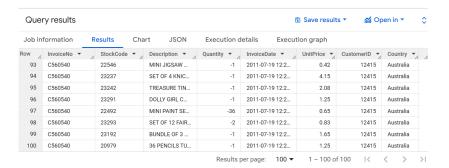


• InvoiceNo 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

SELECT *
FROM neon-rite-456102-e4.modulabs_project.data
WHERE InvoiceNo LIKE 'C%'
LIMIT 100;

[결과 이미지를 넣어주세요]

마지막 100이 보이게 이미지 잘랐습니다.

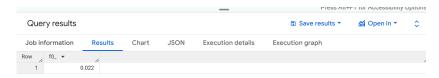


• 구매 건 상태가 Canceled 인 데이터의 비율(%) - 소수점 첫번째 자리까지

SELECT ROUND(SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END)/ COUNT(*), 3) FROM neon-rite-456102-e4.modulabs_project.data

[결과 이미지를 넣어주세요]

Big Query에서 percentage로 결과를 보여주는 함수를 찾을 수 없어서 소수점 세째 자리에서 반올림 하여 결과 도출했습니다.

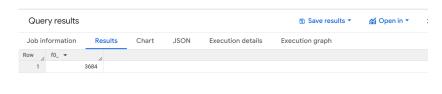


StockCode 살펴보기

• 고유한 StockCode 의 개수를 출력하기

```
SELECT COUNT(DISTINCT StockCode)
FROM neon-rite-456102-e4.modulabs_project.data;
```

[결과 이미지를 넣어주세요]



- 어떤 제품이 가장 많이 판매되었는지 보기 위하여 StockCode 별 등장 빈도를 출력하기
 - 。 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM neon-rite-456102-e4.modulabs_project.data
GROUP BY StockCode
ORDER BY sell_cnt DESC
LIMIT 10;
```

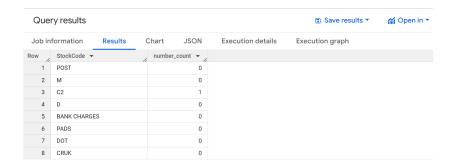
[결과 이미지를 넣어주세요]

Query results					Save results ▼	⋒ Ор∉
Job information Results		Chart	Chart JSON Execution details		Execution graph	
Row	StockCode ▼	sell_c	nt 🔻			
1	85123A		2065			
2	22423		1894			
3	85099B		1659			
4	47566		1409			
5	84879		1405			
6	20725		1346			
7	22720		1224			
8	POST		1196			
9	22197		1110			
10	23203		1108			

- StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - 。 **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
SELECT StockCode,
LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
FROM neon-rite-4456102-e4.modulabs_project.data
)
WHERE number_count BETWEEN 0 AND 1;
```

[결과 이미지를 넣어주세요]



- StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

SELECT

ROUND(SUM(CASE WHEN StockCode IN ('POST', 'M', 'C2','D','BANK CHARGES','PADS','DOT','CRUK') THEN 1 ELSE 0 END) / COUNT(*),4)

FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]

Big Query에서 percentage로 결과를 보여주는 함수를 찾을 수 없어서 소수점 네째 자리에서 반올림 하여 결과 도출했습니다.



• 제품과 관련되지 않은 거래 기록을 제거하기

DELETE FROM neon-rite-456102-e4.modulabs_project.data

WHERE StockCode IN (

SELECT DISTINCT StockCode

FROM (

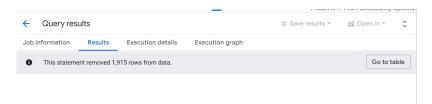
SELECT StockCode,

LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count

FROM neon-rite-456102-e4.modulabs_project.data)

WHERE number_count BETWEEN 0 AND 1);

[결과 이미지를 넣어주세요]

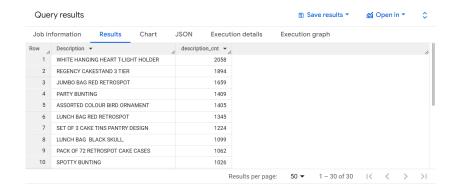


Description 살펴보기

• 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기

SELECT Description, COUNT(*) AS description_cnt FROM neon-rite-456102-e4.modulabs_project.data GROUP BY Description ORDER BY description_cnt DESC LIMIT 30;

[결과 이미지를 넣어주세요]



• 서비스 관련 정보를 포함하는 행들을 제거하기

DELETE FROM neon-rite-456102-e4.modulabs_project.data WHERE Description IN('High Resolution Image','Next Day Carriage')

[결과 이미지를 넣어주세요]

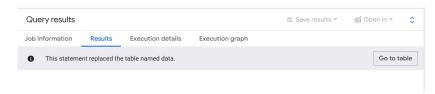


• 대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기

CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.data AS
SELECT

* EXCEPT (Description),
UPPER(Description) AS Description
FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]

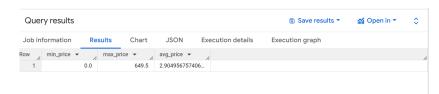


UnitPrice 살펴보기

• UnitPrice 의 최솟값, 최댓값, 평균을 구하기

SELECT MIN(UnitPrice) AS min_price, MAX(UnitPrice) AS max_price, AVG(UnitPrice) AS avg_price FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]



• 단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기

SELECT COUNT(Quantity) AS cnt_quantity, MIN(Quantity) AS min_quantity, MAX(Quantity) AS max_quantity, AVG(Quantity) AS avg_FROM neon-rite-456102-e4.modulabs_project.data
WHERE UnitPrice=0

[결과 이미지를 넣어주세요]

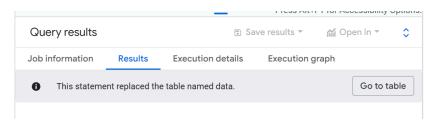


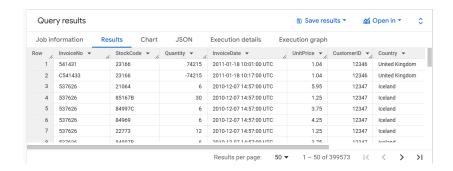
• UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기

CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.data AS SELECT *
FROM neon-rite-456102-e4.modulabs_project.data
WHERE UnitPrice >0;

[결과 이미지를 넣어주세요]

데이터 처리후 남은 행은 399,573으로 확인됩니다.





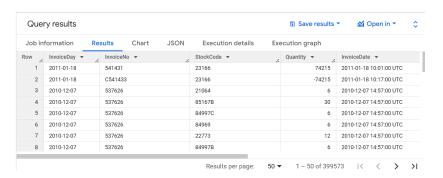
11-7. RFM 스코어

Recency

• InvoiceDate 컬럼을 연월일 자료형으로 변경하기

SELECT DATE(InvoiceDate) AS InvoiceDay, * FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]



• 가장 최근 구매 일자를 MAX() 함수로 찾아보기

SELECT MAX(InvoiceDate) AS most_recent_date FROM neon-rite-456102-e4.modulabs_project.data;

[결과 이미지를 넣어주세요]

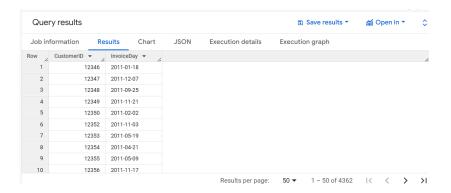


• 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기

SELECT CustomerID,

MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM neon-rite-456102-e4.modulabs_project.data
GROUP BY CustomerID;

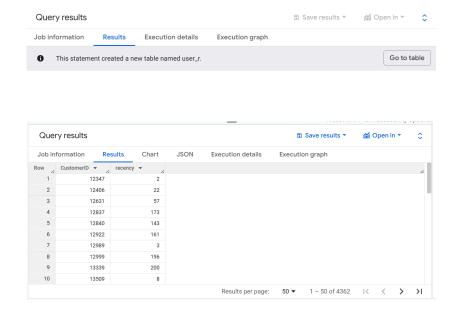
[결과 이미지를 넣어주세요]



• 가장 최근 일자(most_recent_date)와 유저별 마지막 구매일(InvoiceDay)간의 차이를 계산하기

```
CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.user_r AS
SELECT
CustomerID,
EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
SELECT
CustomerID,
MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM neon-rite-456102-e4.modulabs_project.data
GROUP BY CustomerID
);
```

[결과 이미지를 넣어주세요]



• 최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 user_r 이라는 이름의 테이블로 저장하기 [결과 이미지를 넣어주세요]

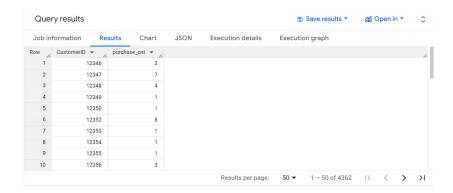


Frequency

• 고객마다 고유한 InvoiceNo의 수를 세어보기

SELECT CustomerID, COUNT(DISTINCT InvoiceNo) AS purchase_cnt FROM neon-rite-456102-e4.modulabs_project.data GROUP BY CustomerID;

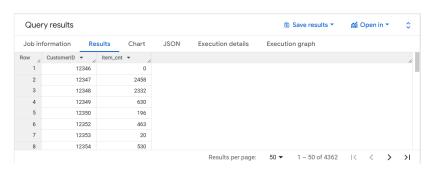
[결과 이미지를 넣어주세요]



• 각 고객 별로 구매한 아이템의 총 수량 더하기

SELECT CustomerID, SUM(Quantity) AS item_cnt FROM neon-rite-456102-e4.modulabs_project.data GROUP BY CustomerID;

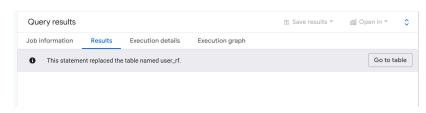
[결과 이미지를 넣어주세요]

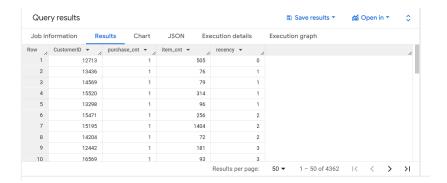


• 전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 user_rf 라는 이름의 테이블에 저장하기

```
CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.user_rf AS
-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
  SELECT
  CustomerID,
   COUNT(DISTINCT InvoiceNo) AS purchase_cnt
   `neon-rite-456102-e4`.modulabs_project.data
  GROUP BY
   CustomerID
   ),
-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
  SELECT
  CustomerID,
   SUM(Quantity) AS item_cnt
  FROM
   `neon-rite-456102-e4`.modulabs_project.data
  GROUP BY
   CustomerID
-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
pc.CustomerID,
pc.purchase_cnt,
ic.item_cnt,
ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
ON pc.CustomerID = ic.CustomerID
JOIN neon-rite-456102-e4.modulabs_project.user_r AS ur
ON pc.CustomerID = ur.CustomerID;
```

[결과 이미지를 넣어주세요]



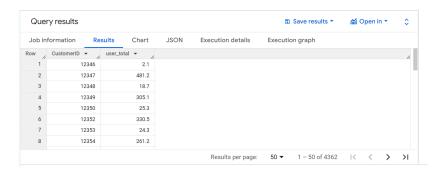


Monetary

• 고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)

SELECT CustomerID, ROUND(SUM(UnitPrice),1) AS user_total FROM neon-rite-456102-e4.modulabs_project.data GROUP BY CustomerID;

[결과 이미지를 넣어주세요]



- 고객별 평균 거래 금액 계산
 - 고객별 평균 거래 금액을 구하기 위해 1) data 테이블을 user_rf 테이블과 조인(LEFT JOIN) 한 후, 2) purchase_cnt 로 나누어서 3) user_rfm 테이블로 저장하기

```
CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.user_rfm AS
SELECT
  rf.CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  AVG(rf.purchase_cnt) AS user_average
FROM neon-rite-456102-e4.modulabs_project.user_rf AS rf
LEFT JOIN (
  SELECT
    data.CustomerID,
    ROUND(SUM(data.UnitPrice), 1) AS user_total
  FROM neon-rite-456102-e4.modulabs_project.data AS data
  GROUP BY data.CustomerID
) AS ut
```

ON rf.CustomerID = ut.CustomerID
GROUP BY rf.CustomerID, rf.purchase_cnt, rf.item_cnt, rf.recency, ut.user_total;
[결과 이미지를 넣어주세요]

Query results

Job information Results Execution details Execution graph

This statement created a new table named user_rfm.

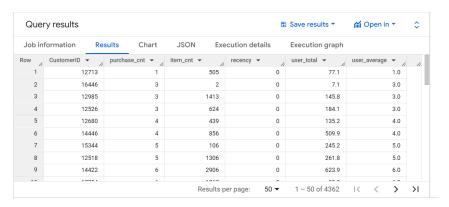
Go to table

RFM 통합 테이블 출력하기

• 최종 user_rfm 테이블을 출력하기

SELECT *
FROM neon-rite-456102-e4.modulabs_project.user_rfm

[결과 이미지를 넣어주세요]



1-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

1) 고객 별로 구매한 상품들의 고유한 수를 계산하기
 2)

user_rfm 테이블과 결과를 합치기

3)

user_data 라는 이름의 테이블에 저장하기

CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.user_data AS

WITH unique_products AS (

SELECT

CustomerID,

COUNT(DISTINCT StockCode) AS unique_products

FROM neon-rite-456102-e4.modulabs_project.data

GROUP BY CustomerID
)

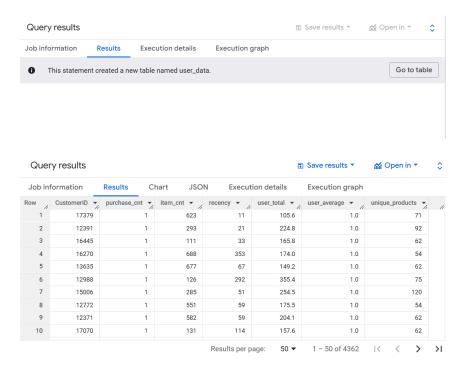
SELECT ur.*, up.* EXCEPT (CustomerID)

FROM neon-rite-456102-e4.modulabs_project.user_rfm AS ur

JOIN unique_products AS up

ON ur.CustomerID = up.CustomerID;

[결과 이미지를 넣어주세요]

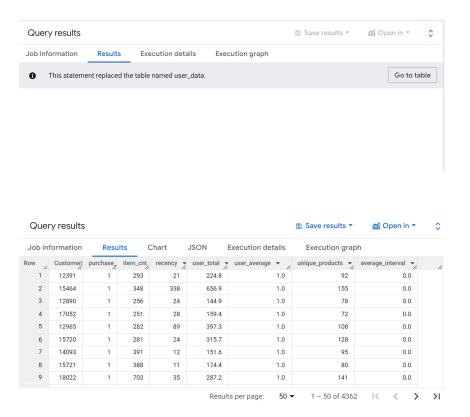


2. 평균 구매 주기

- 고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)
 - 균 구매 소요 일수를 계산하고, 그 결과를 user_data 에 통합

```
CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.user_data AS
WITH purchase_intervals AS (
 -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
 SELECT
 CustomerID,
  CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
 -- (1) 구매와 구매 사이에 소요된 일수
  SELECT
   CustomerID,
   DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
   neon-rite-456102-e4.modulabs_project.data
  WHERE CustomerID IS NOT NULL
 GROUP BY CustomerID
)
SELECT u.*, pi.* EXCEPT (CustomerID)
FROM neon-rite-456102-e4.modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

[결과 이미지를 넣어주세요]

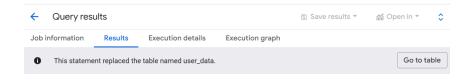


3. 구매 취소 경향성

- 고객의 취소 패턴 파악하기
 - 1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
 - 2) 취소 비율(cancel_rate): 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
 - 취소 빈도와 취소 비율을 계산하고 그 결과를 user_data 에 통합하기 (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE neon-rite-456102-e4.modulabs_project.user_data AS
WITH TransactionInfo AS (
 SELECT
  CustomerID,
  COUNT(InvoiceNo) AS total_transactions,
  SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) AS cancel_frequency
 FROM neon-rite-456102-e4.modulabs_project.data
 GROUP BY CustomerID
)
SELECT
 u.*,
 t.* EXCEPT(CustomerID),
 ROUND(SAFE_DIVIDE(t.cancel_frequency, t.total_transactions), 2) AS cancel_rate
FROM neon-rite-456102-e4.modulabs_project.user_data AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```

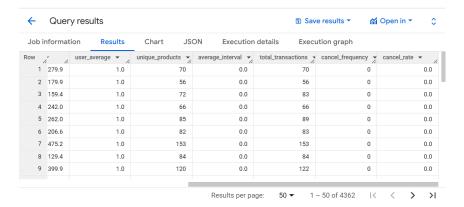
[결과 이미지를 넣어주세요]



• 다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 user_data 를 출력하기

SELECT *
FROM neon-rite-456102-e4.modulabs_project.user_data

[결과 이미지를 넣어주세요]



회고

[회고 내용을 작성해주세요]

Keep: step by step 학습 내용을 잘 따라갔고, 몇개의 명령어는 익숙해졌다. 자잘한 실수도 줄어들었다.(e.g. 콤마 사용, 괄호사용, 따옴표 사용등과 파일명 변경등)

Problem: WITH 구문등 좀 더 익숙해져야 할 명령문이 많다. SELECT / FROM / WHERE 에 각각 쓸 수 있는 구문들이 헷갈린다. 예를들어 WHERE는 함수가 쓰일 수 없다는 것 등.... 단계가 좀 복잡해지면 당황하는데, 차근차근 구문을 읽어보는 연습을 해야할 거 같다.

Try: 자주 연습해보는 방법이 최선 인 것 같다. 시간을 더 들여야 할듯.